

INF-8239 · Unidad 01 · Ejercicio 02

Ensamblados, reducción dimensional y Green AI

Autor: Edwin Ramón José Nolasco

Código: U01.E02

Repositorio

<https://github.com/rhaynel19/Ejercicio-01-Dataset-p-blico-y-SVM-reproducible>

Objetivo

Comparar seis configuraciones de SVM, Random Forest y boosting, con y sin PCA, usando tres repeticiones temporales y la mediana como resumen robusto.

Dataset

Wisconsin Diagnostic Breast Cancer (WDBC), 569 observaciones y 30 variables numéricas. Se reutiliza el dataset y el target aprobados en el Ejercicio 01.

Decisión resumida

La mejor configuración por F1 macro mediano fue svm, con F1 0.9812, tiempo de entrenamiento 0.025 s y tamaño serializado 28.5 KB.

1. Metodología reproducible

Partición

En cada repetición se usa una partición 80/20 estratificada. Las semillas temporales son 42, 43 y 44. El conjunto de prueba permanece separado durante el ajuste.

Configuraciones

SVM, SVM + PCA, Random Forest, Random Forest + PCA, HistGradientBoosting y HistGradientBoosting + PCA. El escalamiento y PCA se integran en Pipeline cuando corresponde.

Métricas

Se miden F1 macro y accuracy. Para Green AI se registran tiempo de entrenamiento, milisegundos por muestra en inferencia, tamaño serializado en KB y parámetros aproximados.

Reducción dimensional

PCA conserva el 95% de la varianza dentro del pipeline. t-SNE se utiliza solo como exploración visual con perplexity 5 y 30; no se utiliza para entrenar ni evaluar modelos.

Interpretación t-SNE

Perplexity 5 enfatiza vecindarios locales y puede fragmentar grupos pequeños; perplexity 30 busca una estructura más global y suaviza la visualización. Las dos figuras se comparan como evidencia exploratoria, no como prueba de separación clínica.


2. Tabla principal: medianas de tres repeticiones

Configuración	F1 macro	Accuracy	Train (s)	Inferencia (ms)	Tamaño (KB)
boosting	0.9619	0.9649	0.720	0.095	315.3
boosting_pca	0.9539	0.9561	0.593	0.097	274.3
random_forest	0.9526	0.9561	0.505	0.589	370.8
random_forest_pca	0.9164	0.9211	0.495	0.564	552.6
svm	0.9812	0.9825	0.025	0.089	28.5
svm_pca	0.9719	0.9737	0.020	0.054	15.7

Interpretación


La mediana reduce la sensibilidad a una sola partición temporal. La elección final debe considerar simultáneamente desempeño y costo, no únicamente el máximo F1.

3. PCA en dos dimensiones




4. t-SNE con perplexity 5

t-SNE del entrenamiento (perplexity=5)




5. t-SNE con perplexity 30

t-SNE del entrenamiento (perplexity=30)



6. Frontera Pareto: desempeño frente a costo



7. Conclusión y trazabilidad

Conclusión

La comparación muestra el compromiso entre discriminación y recursos. Se seleccionó svm como mejor alternativa cuantitativa por F1 macro mediano, pero la decisión debe conservar la frontera Pareto y priorizar configuraciones no dominadas cuando la diferencia de F1 sea pequeña.

Evidencias

Los resultados por repetición están en results_repetitions.csv; las medianas en results_median.csv; los modelos están serializados en reports/model_*.joblib.

IA utilizada

Se utilizó GitHub Copilot para proponer estructura, explicar errores, sugerir pruebas y revisar redacción. Se verificaron manualmente dataset, particiones, configuraciones, repeticiones, métricas, figuras, archivos serializados y pruebas.

Reproducción

Desde actividad 2: python -m pip install -r requirements.txt; \$env:PYTHONPATH='.'; python run_experiment.py; python -m pytest -q.