

Entrega individual INF-8239

Comparacion de datasets y experimento SVM

Repositorio: <https://github.com/rhaynel19/Ejercicio-01-Dataset-p-blico-y-SVM-reproducible>

Ficha comparativa

Dataset	Procedencia	Tamano	Decision
WDBC	UCI / sklearn	569 x 30	Principal: aprobado
Iris	UCI / sklearn	150 x 4	Alternativa: aprobada

Pregunta: distinguir diagnosticos malignos y benignos con un SVM

Auditoria: 569 filas, 30 variables, 0 ausentes, 0 duplicados; target fuera de X.

Prevencion de fuga: StandardScaler dentro de Pipeline; GridSearchCV solo sobre X_train.

Resultados principales


Modelo	F1 macro	ROC-AUC
Dummy mayoritario	0.3871	--
SVM base	0.9812	0.9950
SVM optimizado	0.9812	0.9977

Mejores parametros: C=10, gamma=0.01


Evidencias: reports/svm_cv_results.csv y reports/svm_summary.json

Figuras del SVM optimizado

Matriz de confusion



Curva ROC



Conclusion

El experimento responde afirmativamente a la pregunta planteada: un SVM con estandarizacion integrada supera ampliamente al baseline mayoritario y mantiene un desempeno muy alto sobre el conjunto de prueba. El baseline alcanza un F1 macro de 0.3871 porque siempre predice la clase dominante; por tanto, no ofrece una discriminacion util entre diagnosticos. El SVM base alcanza F1 macro de 0.9812 y ROC-AUC de 0.9950. La busqueda de hiperparametros selecciona $C=10$ y $\gamma=0.01$, con ROC-AUC de 0.9977 y el mismo F1 macro redondeado a cuatro decimales. La mejora mas visible aparece en la capacidad de ordenar correctamente los casos, aunque el F1 no cambia con el redondeo.

La conclusion es defendible porque la evaluacion separa el conjunto de prueba antes del ajuste y reserva ese conjunto para una sola medicion final. Ademas, el escalamiento ocurre dentro del pipeline, de modo que no se calculan medias ni desviaciones usando observaciones de prueba. La validacion cruzada estratificada conserva la proporcion de clases y permite comparar configuraciones sin convertir el conjunto final en parte del proceso de seleccion. La auditoria no encontro ausentes, duplicados ni una columna objetivo filtrada dentro de las variables predictoras.

Aun asi, el resultado no debe interpretarse como una validacion clinica. WDBC es un dataset pequeno y clasico, sus observaciones no representan necesariamente una poblacion actual y la particion aleatoria no modela variaciones entre centros, instrumentos o pacientes. El siguiente paso seria validar el pipeline con una fuente externa y reportar intervalos de incertidumbre, sensibilidad especifica y analisis de errores por clase. En esta entrega, la principal evidencia es metodologica: el flujo es reproducible, las decisiones estan registradas y el codigo probado separa transformacion, entrenamiento y evaluacion de manera clara.